

Tecniche di segmentazione applicate all'identificazione delle malattie nelle foglie di ulivo

Questo articolo presenta il progetto di elaborazione delle immagini finalizzato alla segmentazione di foglie di ulivo, riproducendo la metodologia descritta nell'articolo [“Olive Spot Disease Detection and Classification using Analysis of Leaf Image Textures”](#) di [Aditya Sinha](#) e [Rajveer Singh Shekhawat](#). L'obiettivo principale è l'isolamento dell'area fogliare malata per la successiva identificazione delle malattie, fra cui la più diffusa globalmente *Peacock spot*, nota anche come *Occhio di Pavone*.

1. Introduzione

La produzione di olio d'oliva e la coltivazione dell'ulivo sono settori cruciali per l'agricoltura nel meridione, ma sono costantemente minacciati da una grande varietà di malattie: patologie come l'infestazione da acari patogeni fungini (*Neofabrea*) e l'Occhio di Pavone (*Spilocaea oleaginea*) possono compromettere seriamente la resa e la salute dell'albero. Il rilevamento manuale di queste malattie è un processo lento, costoso e soggetto ad errori. Pertanto, l'automazione del processo di diagnosi tramite tecniche di computer vision e image processing è diventata un'area di ricerca di grande interesse. Il primo e più critico passo in questo processo è la segmentazione, ovvero la separazione precisa della foglia (e delle sue lesioni) dallo sfondo dell'immagine, al fine di estrarre feature rilevanti per una classificazione successiva attuabile mediante modelli di Machine Learning.

2. Lavori Correlati (Related Works)

In letteratura, la diagnosi automatizzata delle malattie delle piante si basa storicamente su due filoni principali. Il primo filone utilizza metodi classici di elaborazione delle immagini: la segmentazione tramite sogliatura (thresholding), come il metodo di Otsu, o metodi basati sul clustering del colore (es. K-Means nel dominio $L^*a^*b^*$ o HSV). A seguito della segmentazione, vengono comunemente estratti descrittori di forma, colore e texture (come la Gray-Level Co-occurrence Matrix o GLCM) da passare a classificatori tradizionali come le Support Vector Machine (SVM) o i K-Nearest Neighbors (KNN).

Il secondo filone, più recente, sfrutta il Deep Learning, in particolare le Reti Neurali Convoluzionali (CNN), che apprendono automaticamente le feature direttamente dai pixel, offrendo grande robustezza a variazioni di luce e sfondi complessi. Tuttavia, i metodi basati sul clustering come il K-Means (l'approccio utilizzato nel paper di riferimento e in questo progetto) rimangono fondamentali in quanto non richiedono enormi set di dati etichettati per l'addestramento e garantiscono una grande interpretabilità della maschera di segmentazione prodotta.

3. Operazioni preliminari

Per facilitare una migliore segmentazione, prima di applicare le tecniche citate di seguito, si è implementato un algoritmo finalizzato all'estrazione della regione appartenente alla foglia a partire da un'immagine RGB. L'obiettivo è separare la foglia dallo sfondo circostante, molto spesso, nel nostro dataset, non uniforme.

L'approccio adottato si basa sull'utilizzo dello **spazio HSV (Hue, Saturation, Value)**, impiegato per individuare la foglia sfruttando la maggiore saturazione cromatica generalmente associata ai tessuti vegetali, combinato a una serie di operazioni di filtraggio morfologico.

La pipeline complessiva è costituita dalle seguenti fasi:

1. Conversione HSV e segmentazione basata sulla saturazione;
2. Pulizia morfologica della maschera (apertura, chiusura, riempimento buchi e rimozione piccole aree);
3. Selezione della componente connessa principale (la foglia);
4. Raffinamento morfologico finale e validazione della componente maggiore.

3.1. Conversione iniziale nello spazio HSV

L'immagine RGB viene convertita nello spazio HSV, dove viene utilizzata la sola componente di **saturazione S**, poiché le foglie presentano generalmente valori di saturazione maggiori rispetto allo sfondo. La soglia viene determinata automaticamente tramite il metodo di Otsu sull'istogramma del canale S, permettendo di ottenere una prima maschera binaria della foglia.

3.2. Filtraggio morfologico e selezione della foglia principale

La maschera binaria ottenuta dalla sogliatura viene migliorata tramite una precisa sequenza di **operazioni morfologiche**:

- **imopen**: apertura per rimuovere il rumore superficiale;
- **imclose**: chiusura per colmare piccole discontinuità;
- **imfill**: riempimento delle regioni interne vuote (buchi) della foglia;
- **bwareaopen**: rimozione di piccole componenti isolate (nello specifico, con area inferiore a 500 pixel).

Successivamente, vengono analizzate le componenti connesse (con la funzione **bwconncomp**) e viene mantenuta solamente quella con area maggiore, assumendo che rappresenti la foglia principale.

3.3. Post-processing finale

La maschera contenente la foglia principale viene ulteriormente rifinita tramite un'ultima operazione di **chiusura morfologica** (**imclose** con un raggio più piccolo) e un nuovo riempimento dei buchi (**imfill**). Infine, viene effettuato un ultimo controllo sulle componenti connesse per garantire l'assenza di artefatti e mantenere rigorosamente un singolo oggetto (quello con area maggiore) come maschera definitiva per le successive operazioni di isolamento delle malattie.

4. Metodologia: Tecniche di Segmentazione a Confronto

Il progetto implementa e mette a confronto due diverse pipeline per la segmentazione della malattia all'interno dell'area fogliare precedentemente isolata (Region of Interest o ROI): il clustering K-Means e la sogliatura basata sull'istogramma (Histogram-based thresholding). Entrambe le modalità operano esclusivamente sui pixel appartenenti alla foglia, escludendo a priori lo sfondo.

4.1 Clustering K-Means

Questa tecnica si basa sul partizionamento spaziale dei colori applicato all'interno del tessuto fogliare. La pipeline segue questi passaggi:

- 1. Estrazione dei dati e spazio colore:** l'immagine viene analizzata nello spazio percettivo CIE $L^*a^*b^*$. Vengono campionati i pixel della maschera fogliare ed estratte le relative componenti di luminosità (L^*) e cromaticità (a^* e b^*), andando a costituire la matrice tridimensionale delle feature (dataLAB).
- 2. k-means clustering:** l'algoritmo raggruppa iterativamente i pixel della foglia in $k=3$ cluster predefiniti, minimizzando la distanza euclidea al quadrato rispetto ai centroidi. Questo permette di suddividere il tessuto fogliare in tre regioni cromaticamente e strutturalmente distinte (es. tessuto sano, lesioni patologiche, variazioni di ombreggiatura).
- 3. Selezione automatica dell'anomalia cromatica:** per identificare matematicamente il cluster associato alla malattia, l'algoritmo calcola il colore medio della foglia sui canali cromatici a^* e b^* . Successivamente, viene selezionato automaticamente il cluster il cui centroide presenta la maggiore distanza euclidea dalla media cromatica della foglia. Questo approccio consente di identificare la patologia come un'anomalia rispetto al tessuto sano, senza imporre rigidamente che le macchie debbano essere necessariamente più scure.

- 4. Rifinitura morfologica:** sulla maschera binaria del cluster infetto viene applicata una pulizia minima per rimuovere il rumore: un'apertura morfologica (imopen con elemento strutturante a disco di raggio 1) e la rimozione di piccolissime aree isolate inferiori a 20 pixel (bwareaopen).

4.2 Segmentazione tramite Istogramma (Histogram Mode)

La seconda modalità adotta un approccio statistico locale focalizzato sulla distribuzione dei pixel della sola regione fogliare, sfruttando le proprietà discriminatorie di un singolo canale cromatico:

- 1. Isolamento del canale a^* :** l'algoritmo estrae i valori del canale cromatico a^* (che mappa la transizione dal verde al rosso/magenta) per i soli pixel validi della foglia, normalizzando i valori in un range $[0, 1]$. L'esclusione preventiva del background impedisce che quest'ultimo alteri il calcolo della distribuzione statistica.
- 2. Sogliatura globale di Otsu:** viene calcolato l'istogramma dei pixel della foglia sul canale a^* normalizzato e viene determinata la soglia ottimale mediante il metodo di Otsu (graythresh), mirata a massimizzare la varianza inter-classe.
- 3. Determinazione della polarità per area minoritaria:** poiché la soglia divide geometricamente la distribuzione in due classi, vengono generate e testate entrambe le polarità possibili (pixel sopra la soglia e pixel sotto la soglia). Il sistema calcola l'estensione in pixel di entrambe le maschere e seleziona automaticamente quella con l'area minore, basandosi sull'assunto biologico che la malattia occupi una porzione minoritaria della superficie fogliare rispetto al tessuto sano.
- 4. Estrazione della ROI e rifinitura:** La maschera risultante viene vincolata alla foglia e ripulita con le medesime operazioni morfologiche utilizzate nella pipeline k-means (imopen e bwareaopen a 20 pixel) per assicurarne la coesione spaziale ed eliminare i falsi positivi isolati.

4.3 Considerazioni Teoriche sulle due Pipeline

Il **k-means** lavora nello spazio tridimensionale $L^*a^*b^*$ sfruttando appieno le relazioni cromatiche e di luminosità della foglia, dimostrandosi altamente robusto e adattabile a variazioni di colorazione complesse, sebbene richieda la specifica del parametro k e l'adozione di metriche di distanza per identificare il cluster target. Il metodo basato su **istogramma** riduce il problema a una dimensione analizzando solo il canale a^* ; è computazionalmente immediato ed efficiente poiché si affida al calcolo diretto di una soglia di Otsu, ma la sua precisione è strettamente dipendente dal contrasto cromatico interno alla foglia e dal fatto che la patologia rappresenti effettivamente la minoranza geometrica dei pixel fogliari.

5. Risultati

In questa sezione vengono presentati e confrontati i risultati ottenuti dalle due pipeline di segmentazione. Il dataset utilizzato è [CNN olive dataset](#), di cui si sono unite le cartelle compresse e prelevate le immagini delle foglie di ulivo affette dall'*Occhio di Pavone*. Si valuta visivamente la precisione dell'estrazione e della pulizia della ROI per entrambe le modalità.

5.1 Metriche di Classificazione e Texture

Per la fase di individuazione e classificazione della malattia, il modello discriminante futuro si affiderà alle feature estratte dall'immagine segmentata. Tali feature prese in considerazione sono:

- **GLCM** (Gray-Level Co-occurrence Matrix), dove vengono valutate metriche specifiche tra cui:
 - **Energia:** quantifica l'uniformità della texture fogliare. Valori elevati indicano una superficie omogenea e regolare, tipica di una foglia sana;
 - **Entropia:** misura il grado di disordine o complessità dell'immagine. Picchi di entropia sono indicatori cruciali della presenza di lesioni patologiche (come macchie o necrosi) che alterano la naturale regolarità della superficie fogliare;
 - **Contrasto:** pesa la differenza di intensità fra i vari pixel dell'immagine. Zone di alto contrasto possono indicare aree infette, specialmente dalla malattia dell'*Occhio di Pavone*;
 - **Omogeneità:** misura la vicinanza della distribuzione degli elementi nella GLCM alla diagonale principale. A differenza del contrasto, alti valori di omogeneità indicano una superficie della foglia più liscia e con transizioni di colore minime e gradualità, indice di una foglia sana.

- **Correlazione:** rappresenta la relazione lineare fra i pixel vicini, permettendo di identificare picchi di area con alti valori di correlazione come aree infette.


Inoltre viene calcolata a fine estrazione feature la **percentuale di infezione**, stimata in base al numero di pixel malati rispetto al totale. Essa viene usata in questa impostazione come target utilizzato per il calcolo della **correlazione statistica** tramite l'indice di Pearson rispetto alle feature estratte.

	r (Pearson)	
Feature	Histogram	K-Means
Energy	-0.0530	-0.1054
Contrast	-0.0605	0.2090
Homogeneity	0.1159	-0.2727
Entropy	0.1168	0.1715
Correlation	0.2309	0.1914

5.2 Confronto Visivo




Immagine originale (A51.JPG)



Rimozione sfondo



Segmentazione histogram



Segmentazione k-means

6. Discussione

In questa sezione si analizzano i risultati ottenuti dall'algoritmo confrontando le pipeline utilizzate e le loro prestazioni, riconoscendo i limiti del paper originale e considerando possibili scenari di sviluppo futuri.

6.1 Valutazione delle prestazioni

Dal confronto fra le due pipeline proposte, si evidenzia una maggiore affidabilità della tecnica utilizzata da k-means, a partire dal risultato ottenuto visivamente dall'estrazione della parte malata. L'accuratezza maggiore di tale metodo rispetto alla sogliatura tramite istogramma è dovuto alla riduzione delle distanze quadrate applicata durante il raggruppamento dei pixel nei cluster per stabilizzare i centroidi: questa operazione si traduce in un'individuazione più consistente delle parti necrotiche della foglia, a costo di computazioni più onerose rispetto alla sogliatura tramite istogramma. Tuttavia, i valori ottenuti dell'indice r sono definibili anomali rispetto alle aspettative teoriche e ai risultati sperimentali del paper. Infatti, le andature delle correlazioni definite dal segno risultano esattamente opposte. Valori come energia ed omogeneità che definiscono l'uniformità dei pixel risultano essere correlati in maniera diretta alla crescita della percentuale di infezione, e non inversa.

6.2 Limiti del progetto

Le limitazioni sono principalmente dovute alle supposizioni poste dal paper sul calcolo delle prestazioni e alla qualità del dataset con cui si è lavorato.

Partendo dal paper, possiamo notare come i valori di correlazione presentati nell'istogramma non corrispondono all'andamento dei diagrammi cartesiani. A livello

sperimentale, nei diagrammi cartesiani presentati, gli indici r di energia ed entropia dovrebbero indicare rispettivamente una correlazione inversa e diretta alla percentuale di infezione, che non coincidono con i valori sperimentali riportati nel diagramma del medesimo. I risultati ottenuti in questa sperimentazione invece tendono verso lo 0, suggerendo una mancanza di correlazione fra la percentuale di infezione e le feature estratte. Questo è dovuto anche all'area considerata: i valori delle feature estratte non sono riferite all'intera foglia, ma solo alla parte necrotica. Ciò comporta una discrepanza importante: le caratteristiche intrinseche dei sintomi dei patogeni non possono essere correlate alla percentuale d'infezione sulla foglia, poiché i valori delle feature ricavati da tali caratteristiche rimarranno simili entro una certa soglia per tutte le foglie, a prescindere dall'estensione della malattia. Rispetto ai risultati presentati in questo esperimento ci sono comunque indici r che si discostano in maniera non indifferente da 0: questo è dovuto in buona parte dalla qualità del dataset utilizzato. Le foglie sono state fotografate in diverse impostazioni e condizioni di illuminazione, esposizione, spazio cromatico e bilanciamenti di bianco. Queste variazioni fotografiche hanno un impatto diretto sull'accuratezza e sulla robustezza dell'algoritmo.



Queste immagini di esempio presenti nel dataset evidenziano come si sono dovuti gestire input eterogenei, influenzando i risultati in questa maniera:

- **Segmentazione dello sfondo:** le venature del legno della prima immagine e l'ombra densa vignettata al bordo della terza immagine rendono l'estrazione della sagoma (edge detection o background subtraction) molto più complessa rispetto al setup ideale, pulito e ad alto contrasto della seconda.

- **Segmentazione della superficie malata:** gli algoritmi che utilizzano soglie cromatiche (negli spazi colore RGB, HSV o LAB) per identificare le aree malate faticano enormemente di fronte a bilanciamenti del bianco scorretti. La dominante gialla della prima immagine rischia di generare falsi positivi per le macchie necrotiche, mentre la grave sottoesposizione della terza immagine comprime la gamma dinamica, nascondendo le sfumature della malattia nei pixel troppo scuri. La seconda immagine fornisce invece un "ground truth" visivo ottimale per tarare i parametri del codice.

Ultimo limite ma non meno importante è la scarsa disponibilità di dataset accessibili e curati nello scenario presentato, e in generale di diverse malattie associate alla pianta d'ulivo, a partire dalla completa assenza di dataset accessibili per la *Neofabrea* studiata nel paper, motivo per cui la segmentazione è stata studiata solo per l'*Occhio di Pavone*.

6.3 Sviluppi futuri

In primis, sarà necessario dover riconsiderare le metriche di valutazione in maniera tale che non ricadano in errori logici come appena dimostrato, soprattutto per quanto riguarda la correlazione statistica. Una supposizione possibile da questa discussione è che i valori ottenuti dalle feature estratte possono comunque essere indicativi di un patogeno specifico rispetto all'intervallo in cui rientrano. Per esempio, colorazioni marroni o grigiastre con sfumature di giallo causate dall'*Occhio di Pavone* possono essere distinguibili dalle macchie rossastre della *Cercosporiosi* (o *Piombatura dell'ulivo*), altra malattia maggiormente diffusa nel Mediterraneo. Tali colorazioni possono essere interpretate negli spazi colore usati nel progetto per identificare una certa malattia, oltre alle feature estratte dalla matrice GLCM, per essere efficacemente usate nei modelli di classificazione.

Sui dati raccolti, con l'accesso ad un dataset più consistente nell'impostazione

fotografica e più curato sarà possibile analizzare con più fedeltà l'accuratezza dell'algoritmo.

In termini di prestazioni si considera la possibilità di implementare un approccio ibrido per l'individuazione della ROI sul tessuto fogliare per bilanciare la velocità di calcolo della sogliatura con istogramma e la maggior finezza di segmentazione da parte del metodo k-means: questo è attuabile utilizzando la sogliatura con istogramma per una scrematura grossolana del background, lasciando al metodo k-means il compito di effettuare una più fine segmentazione della malattia. Se si volesse optare per un algoritmo di rimozione dello sfondo più robusto e dovesse nascere la necessità di diminuire il carico di lavoro al processo di segmentazione, il flusso potrebbe implementare l'algoritmo SLIC per la rimozione del background, capace di fornire un approccio più dinamico che non si basi su soglie decise a priori.

Infine, l'algoritmo è di sua natura versatile, permettendo la possibilità di poterne studiare l'applicazione non solo sulle foglie di ulivo, ma su malattie di altre piante che presentano come sintomi lo scolorimento o la necrotizzazione di parti del tessuto fogliare.